

МЕТОДОЛОШКА СКИЦА

AI-Driven Forecasting and Optimization of Photovoltaic Energy Storage and Market Selling Strategies in European Electricity Markets

ВОВЕД ВО НАУКАТА ЗА ПОДАТОЦИ

Христина Ѓорѓиевска 233215 | Огнен Младеновски 233108

1. Опис на проблемот кој го решаваме

Целта на проектот е да се изгради систем за управување со фотоволтаично (PV) производство и складирање на енергија во услови на неизвесни пазарни цени и временски услови. проблемот спаѓа во категоријата Sequential Decision-Making Under Uncertainty: во секој временски чекор, системот одлучува дали произведената електрична енергија да се продаде на пазарот или да се складира во батерија за продажба кога цената ќе биде повисока.

Системот ќе се базира на три слоеви:

- **Environment** – ERA5 метеоролошки податоци + PVGIS фотоволтаично производство
- **Market** – ENTSO-E Day-Ahead пазарни цени на електрична енергија
- **Decision** – ML/оптимизациски модел кој носи одлуки врз основа на тековната состојба и податоците од претходните два слоја

Познати inputs во секој момент ќе ни бидат: состојба на батерија, тековно PV производство, метеоролошки услови и историја на цени.

Непознати inputs ќе ни бидат: идно PV производство и идни цени.

2. Извори на податоци

Извор	Тип на податоци	Зошто ни се потребни
ERA5	Метеоролошки податоци за секој час: ssrd (зрачење), t2m (температура), u10/v10 (ветер), tcc (облачност)	Input features за PV forecasting и price forecasting
PVGIS	PV производство за секој час по локација и параметри (tilt, azimuth)	Тренинг податоци за модел за PV производство; baseline за валидација
ENTSO-E	Day-Ahead цени	Target променлива за price forecasting; reward сигнал при оптимизација

3. Истражувачки прашања и методологија

Почетните експерименти ќе се изведуваат за една избрана европска држава (пр. Германија), а подоцна методологијата може да се прошири и на повеќе држави.

RQ1- Предвидување на цени на електрична енергија

Цел: Колку точно можат да се предвидат Day-Ahead цените (€/MWh) со користење на историски пазарни, метеоролошки и PV податоци?

Информациите кои му ги даваме на моделот се features и ќе ги поделиме на неколку групи:

1. Цени од минатото - бидејќи преку цената од вчера можеме да предвидиме денешна

- Цена пред 1 час
- Цена пред 24 часа (ист час вчера)
- Цена пред 168 часа (ист час минатата недела)

2. Календарски информации - цените преку недела и за викенд се разликуваат

- Час од денот (0 - 24)
- Ден во неделата
- Дали е викенд/празник

3. Временска прогноза (ERA5) - бидејќи ладно време = повеќе греење = поголема побарувачка = повисока цена

- Температура
- Ветер
- Сончева радијација

4. Фотоволтаични податоци (PVGIS) - кога Сонцто произведува многу струја, цената паѓа

- Колку енергија произведуваат соларните панели во тој час.

Модели кои можеме да ги користиме:

1. Persistence Baseline (едноставен baseline)

- „утрешната цена = денешната цена” -> ова е точката на споредба, секој нареден модел очекуваме да биде подобар од ова

2. XGBoost / LightGBM

- не разбираат редослед сами по себе (немаат меморија)
- му даваме lagged features рачно (цена пред 1 час, 24 часа и 1 недела)

3. LSTM (Long Short-Term Memory) - ова е невронска мрежа со меморија (дизајнирана за временски серии)

- памти претходни вредности
- потребни се повеќе податоци
- треба да работи подобро од XGBoost кога имаме многу податоци

4. Temporal Fusion Transformer (TFT) - најнапреден од сите претходни модели бидејќи работи со временски серии со надворешни фактори.

- разбира и цени од минатото и временска прогноза заедно
- треба да даде најдобри резултати

Опис на задачата:

1. Подготовка на податоци

- Сите три податочни множества се спојуваат според Datetime (UTC), се добива една табела каде секој ред е еден час и ги содржи сите информации за истиот.

2. Креирање на features

- од споената табела ќе треба да се креираат нови колони:
 1. lagged цени: price_lag_1h, price_lag_24h, price_lag_168h
 2. Час од денот, ден во неделата, дали е викенд/празник
 3. Директно од PVGIS добива P
 4. Директно од ERA5 добива t2m, u10, v10, ssrd, tcc

3. Поделба на податочното множество

- Податоците ќе бидат поделени хронолошки на train, validation и test сетови за да се избегне data leakage.

4. Тренирање

- Прво тренираме Persistence baseline. Потоа тренираме XGBoost со сите features, па LSTM. Секој нареден модел очекуваме да биде подобар од претходниот.

5. Евалуација

- За секој модел ќе пресметаме MAE, RMSE и MAPE на тест сетот и ќе споредуваме.

Метод	Опис
Persistence	Секој нареден модел мора да биде подобар
XGBoost / LightGBM	Gradient boosting со lagged prices, rolling averages, hour-of-day, day-of-week, ERA5 features
LSTM	Рекурентна невронска мрежа; памти долгорочни зависности во временската серија на цени

RQ2 - Предвидување на PV производство

Цел: Колку ефикасно ERA5 метеоролошките податоци и PVGIS податоците го предвидуваат PV производството за секој час?

Според податоци за PV производство, сакаме да предвидиме колку енергија ќе се произведе во следните часови (колона P).

Ова е важно бидејќи ако знаеме колку енергија ќе произведеме утре, можеме подобро да одлучиме дали да ја чуваме енергијата или да ја продаваме.

Влезни податоци ни се:

1. Директна, дифузна и рефлектирана радијација (Gb, Gd, Gr)
2. Висина на Сонце (H_sun; 0 = зајдисонце, 90 = зенит)
3. Температура (T2m) - панелите работат послабо на многу висока температура

- 4. Брзина на ветер (WS10m)** - лесно ги лади панелите = малку го подобрува производството
- 5. Lag вредности на P** - производство пред 1 час и 24 часа

Модели кои можеме да ги користиме:

- 1. Persistence Baseline** - служи само како точка на споредба
- 2. XGBoost / LightGBM** - му ги предаваме радијацијата, температурата, висината на Сонцето како влезни податоци и тој ја учи каква е врска со производството. Би требало да предвидува добро бидејќи врска помеѓу Сонце и PV производство е директна и предвидлива.
- 3. LSTM** - за разлика од XGBoost, го разбира сама редоследот (пример знае дека по 13:00 доаѓа 14:00). Би било корисно за фаќање на дневен циклус на производство (наутро расте, попладне опаѓа).

Опис на задачата:

1. Подготовка на податоците - треба да ги споиме ERA5 и PVGIS според Datetime (UTC). Ќе ги користиме само часовите каде H_sun е поголемо од 0 (значи дека е преку ден) бидејќи преку ноќ производството секогаш е 0.

2. Креирање на features

- Директно од PVGIS добива Gb, Gd, Gr, H_sun
- Директно од ERA5 добива t2m, ws10m
- Lagged за P: P_lag_1h, P_lag_24h
- Час од денот, месец, ...

3. Поделба на податочното множество

- Податоците ќе бидат поделени хронолошки на train, validation и test сетови за да се избегне data leakage.

4. Тренирање

- Прво Persistence baseline, потоа XGBoost, па на крај LSTM.

5. Евалуација

- За секој модел ќе пресметаме MAE, RMSE, MAPE на тест сетот. Треба да ставиме фокус на грешката во облачни денови бидејќи тоа е најтешкиот case.

Метод	Опис
PVGIS - Физички модел	Директна пресметка: зрачење * ефикасност * темп. корекција - служи за споредба
XGBoost со ERA5 features	Tabular ML; карактеристики: ssrd, t2m, solar elevation angle, hour-of-day, month

LSTM	Ако XGBoost не е доволно точен - истиот сет на features ама со рекурентна архитектура
------	---

RQ3 - Оптимална стратегија за управување со батерија

Цел: Која стратегија за складирање и продажба ги максимизира приходите при неизвесни цени и неизвесно PV производство?

Опис на проблемот:

1. Соларни панели кои произведуваат струја
 2. Батерија која може да ја складира таа струја
 3. Пазар на кој можеме да ја продадеме
- секој час треба да донесеме одлука дали да ја полниме батеријата, да ја продаваме или да не правиме ништо во моментот.
 - **Цел:** да се продава кога цената е висока, да се складира кога цената е ниска
 - Идните цени (предвидени од RQ1, не се 100% точни) и идното PV производство (предвидено во RQ2, исто не е 100% точно) - **донесуваме одлука под неизвесност**

Можни пристапи:

1. Rule-based classification (едноставно, ама не е оптимално)

- ќе треба да дефинираме рачно одредени правила, пример:
Ако цената е над праг X -> продавај
Ако цената е под праг X -> складирај

2. Оптимизација

- Ќе користиме Model Predictive Control (MPC), реализиран преку решавање на линеарен оптимизациски проблем во rolling horizon.
- Во секој временски чекор оптимизацијата ќе ги користи предвидените цени и PV производство за наредните 24 часа и ќе ја пресметува оптималната стратегија за полнење, празнење и продажба на енергија.
- Алгоритмот ќе ги почитува ограничувањата на батеријата: максимален капацитет, минимален капацитет и максимална брзина на полнење/празнење.
- **влез:** ќе ги има предвидените цени од RQ1 + предвиденото производство од RQ2
- **излез:** оптимален распоред - кога точно да полниме или да празниме (продаваме)

Опис на задачата:

1. Влез

- За секој ден ги земаме предвидените цени од RQ1 и предвиденото производство од RQ2 за наредните 24 часа.

2. Rule-based baseline - тука ќе дефинираме едноставни правила: (ни служи за споредба)

- Ако предвидена цена > праг X = **продавај**

- Ако предвидена цена < праг X = **полни батерија**

3. Оптимизација (MPC)

- Ќе се изврши MPC оптимизација врз основа на предвидените цени и предвиденото PV производство.

- За секој временски чекор ќе се пресметува оптималната акција (продавање, складирање или празнење на батеријата).

- Целта е максимизација на вкупниот приход при почитување на ограничувањата на батеријата.

4. Евалуација

- Ќе споредуваме вкупна заработка: Rule-based vs MPC оптимизација. Исто така би можело да споредуваме со Perfect Foresight (сценарио каде цените се познати однапред) за да видиме колку губиме поради неизвесноста.

Метод	Опис
Rule-based baseline	Threshold правила: ако цената > X €/MWh - продај - инаку складирај
Model Predictive Control (MPC)	LP/MIP оптимизација во rolling horizon (N=24h); inputs се прогнозите од RQ1 и RQ2

RQ4 - Влијание на неизвесноста врз стратегијата

Цел: Колку е чувствителна оптималната стратегија на грешки во предвидувањето?

Ќе треба намерно да се додадат грешки во предвидувањето за да видиме што се случува со заработката: (симулаци - ќе имаме сценарија со различни грешки и ќе треба да видиме како се менува резултатот). Пример:

- Ако цената ја предвидиме со грешка +/-10% - колку ќе изгубиме?

- Ако PV производството го предвидиме со грешка од +/-20% - дали стратегијата се уште работи?

- Кое предвидување е поважно - дали на цената или на производството?

Излез: ќе добиеме заклучок налик на следново: „Стратегијата е многу чувствителна на грешки во цената, но поотпорна на грешки во PV производството” или обратно.

Опис на задачата:

1. Base сценарио

- Ја пуштаме оптимизацијата од RQ3 со вистинските предвидувања од RQ1 и RQ2 и ја запишуваме заработката.

2. Додавање грешки

- Ќе треба рачно да ги нарушуваме предвидувањата:

пример: за цена +- 10%, +-20%, +-30%, истото и за PV производството

- за секое сценарио ја повторуваме оптимизацијата од RQ3.

3. Monte Carlo симулации

- Наместо да имаме фиксни грешки, ќе генерираме 1000 случајни сценарија со различни грешки и ќе гледаме каква е дистрибуцијата на заработката.

4. Заклучок

- Ќе ги споредуваме резултатите и ќе заклучуваме кое предвидување е покритично (грешката во цената или грешката во производството).

Метод	Опис
Monte Carlo симулации	1000+ сценација со стохастички реализации на цени и производство; дистрибуција на приходи
Scenario Analysis	Дефинирани стресни сценарија: цени -20%, зрачење -30%, екстремни денови
Perfect Information	Разлика во приход: Perfect Foresight vs реален модел - квантификација на вредноста на прогнозите